



Bilgisayar Mühendisliği Tanıtım Günleri

AI Tanıtım Sistemi — 2025

DATA & KNOWLEDGE BASE

İş Paketi B — Detaylı Teknik Doküman

Temmuz 2025

Alan	Bilgi
Doküman Kodu	İTÜ-AI-B — Data & Knowledge Base
Versiyon	v1.0
Durum	Taslak — Ekip Onayı Bekleniyor
Sorumlu Ekip	Data Ekibi
Son Güncelleme	Temmuz 2025
Bağımlı Modüller	C (AI Motoru), D (Profil Analizi), E (Frontend)

1. Genel Bakış1. Genel Bakış

Bu doküman, İTÜ BBF AI Tanıtım Sistemi'nin temel veri altyapısını tanımlar. AI konuşma motorunun doğru, güncel ve ikna edici cevaplar üretebilmesi için gereken tüm veri kaynaklarını, yapılandırma yöntemlerini ve kalite kriterlerini kapsar.

Knowledge base olmadan AI sistemi çalışmaz. Bu iş paketi, projenin en kritik bağımlılığıdır ve Gün 1'den itibaren paralel yürütülmelidir.

1.1 Amaç

- İTÜ Bilgisayar Mühendisliği hakkında doğru, güncel, kaynaklı veri toplamak
- Bu veriyi AI sisteminin erişebileceği vektör tabanlı bir knowledge base'e dönüştürmek
- Hallucination (uydurma bilgi) riskini sıfıra indirmek
- İkna edici ve etik konuşma içeriği için temel sağlamak

1.2 Kapsam Dışı

- Diğer üniversitelerin verileri (kötüleme riski — ETİK KURAL)
- Doğrulanamayan kişisel hikayeler veya anekdotlar
- Dini, siyasi veya sosyal hassas içerikler
- Gerçek zamanlı fiyat/maaş verisi (statik snapshot kullanılır)

2. Veri Kategorileri ve Kaynaklar

2.1 B1 — Kurumsal & Akademik Veriler

İTÜ'nün resmi kurumsal konumunu ve akademik gücünü belgeleyen verilerdir. Bu veriler en güvenilir ve en ikna edici içerikleri oluşturur.

2.1.1 Uluslararası Sıralamalar

Kaynak	Kapsam	URL / Erişim	Güncelleme
QS World University Rankings	Genel + CS özelinde sıralama	topuniversities.com	Yıllık (2025 verisi)
Times Higher Education	Araştırma etkisi, uluslararasılaşma	timeshighereducation.com	Yıllık
THE Young University Rankings	50 yaş altı üniversiteler	timeshighereducation.com	Yıllık
SCImago Institutions Rankings	Araştırma çıktısı, atıf	scimagoir.com	Yıllık
URAP World Ranking	Akademik performans	urapcenter.org	Yıllık

2.1.2 YÖK & Ulusal Veriler

- YÖK Atlas: Mezun istihdam ve maaş istatistikleri
 - URL: yokatlas.yok.gov.tr
 - İndirilecek: Bilgisayar Mühendisliği mezun takip raporu
- ÖSYM Kılavuzu: Taban puanlar, kontenjanlar, başarı sıralaması
 - Son 5 yılın taban puan trendi hesaplanacak
- İTÜ Faaliyet Raporları: Resmi istatistikler
 - itu.edu.tr/hakkimizda/faaliyet-raporlari

2.1.3 İTÜ Bölüm Sayfası Verileri

- Öğretim üyesi listesi ve uzmanlık alanları
- Aktif araştırma grupları ve laboratuvarlar
- Lisans ders programı özeti
- Çift anadal / yandal imkanları
- Uluslararası ortak programlar (Erasmus+, ikili anlaşmalar)
- Öğrenci topluluğu ve kulüp listesi

2.2 B2 — Mezun & Kariyer Verileri

Bu kategori, öğrencilerin en çok merak ettiği 'sonuç' verilerini içerir. İkna gücü en yüksek veri tipidir.

2.2.1 İstihdam İstatistikleri

Veri Noktası	Kaynak	Hedef Değer
Mezuniyet sonrası 6 ay içinde istihdam oranı	YÖK Atlas / İTÜ Kariyer	%XX
Yurt dışı yüksek lisans kabul oranı	Bölüm istatistikleri	%XX
Ortalama başlangıç maaşı (2024)	LinkedIn / Glassdoor	XX.XXX ₺
FAANG / büyük tech şirket çalışan sayısı	LinkedIn manuel sayım	XXX kişi+
Girişim kuran mezun sayısı	İTÜ Çekirdek verileri	XXX+

2.2.2 Başarılı Mezun Profilleri

Her profil için şu format kullanılacak (isim-soyisim değil, pozisyon+şirket formatında gizlilik korunacak):

- Pozisyon ve şirket adı
- Mezuniyet yılı
- Kariyer hikayesi özeti (2-3 cümle)
- İTÜ'de hangi fırsatların bu başarıya katkısı olduğu

Hedef: En az 15-20 çeşitli profil (FAANG, startup, akademi, kamu, yurt dışı)

2.2.3 Şirket Partnerships

- İTÜ'ye kampüse gelen şirketler listesi (kariyer günlerinden)
- Staj anlaşması olan şirketler
- Burs veren kurumlar

2.3 B3 — Öğrenci Deneyimi Verileri

Öğrencileri ikna ederken 'buradaki hayat nasıl?' sorusunu yanıtlayan veriler.

2.3.1 Kampüs & Sosyal Yaşam

- Öğrenci kulüpleri listesi (teknoloji odaklı olanlar öne çıkarılacak)
 - IEEE İTÜ, ACM İTÜ, Robotik Kulübü, Yapay Zeka Topluluğu vb.
- Hackathon ve yarışma geçmişi
 - Son 3 yılda kazanılan ulusal/uluslararası ödüller
- Kütüphane ve lab çalışma saatleri
- Öğrenci projeleri ve portföy örnekleri

2.3.2 Sık Sorulan Sorular Bankası

Geçmiş tanıtım günlerinden ve öğrenci forumlarından derlenen gerçek sorular:

Soru Kategorisi	Örnek Sorular	Öncelik
Kariyer	Mezun olunca ne iş bulunur? Maaşlar ne kadar?	Yüksek

Soru Kategorisi	Örnek Sorular	Öncelik
Akademik	Dersler zor mu? Bölüm sıralaması nedir?	Yüksek
Kampüs hayatı	Yurt durumu nasıl? Sosyal aktiviteler var mı?	Orta
Puan/Sıralama	Kaç puanla girilir? Taban puan nedir?	Yüksek
Araştırma	Lisans döneminde araştırma yapılabilir mi?	Orta
Yurt dışı	Erasmus imkanı var mı? Yurt dışı master yapılır mı?	Orta
Diğer bölümlerle karşılaştırma	Neden burayı tercih etmeliyim?	Yüksek

3. Knowledge Base Yapılandırması (B4)

3. Knowledge Base Yapılandırması (B4)

Toplanan ham veri, AI sisteminin erişebilmesi için vektör tabanlı bir knowledge base'e dönüştürülecektir. Bu süreç RAG (Retrieval-Augmented Generation) mimarisini kullanır.

3.1 Teknik Mimari

Knowledge base için önerilen teknoloji yığını:

Bileşen	Teknoloji	Neden?
Embedding Modeli	text-embedding-3-small (OpenAI) veya sentence-transformers	Türkçe dil desteği
Vector Store	ChromaDB (yerel) veya FAISS	Offline çalışır, kurulum basit
Chunking Kütüphanesi	LangChain TextSplitter	Akıllı metin bölme
Metadata Yönetimi	JSON + Python dict	Basit, hızlı
Test Framework	LangChain Evaluation	Retrieval kalite testi

3.2 Veri İşleme Pipeline

Adım 1 — Ham Veri Hazırlama

- Tüm veriyi Markdown (.md) formatına çevir
- Her dosyaya başlık, kategori, kaynak, tarih metadata'sı ekle
- Doğrulanamayan bilgileri işaretle veya çıkar
- Türkçe karakter kontrolü yap

Adım 2 — Chunking Stratejisi

Chunk boyutu ve overlap değerleri kritiktir:

Veri Tipi	Chunk Boyutu	Overlap	Gerekçe
Kısa FAQ cevapları	200-300 token	50 token	Tam cevap bir chunk'a sığsın
İstatistik paragrafları	400-500 token	100 token	Bağlam korunsun
Mezun hikayeleri	300-400 token	75 token	Hikaye akışı bozulmasın
Teknik açıklamalar	500-600 token	100 token	Detay kaybolmasın

Adım 3 — Metadata Şeması

Her chunk için zorunlu metadata alanları:

- category: [kariyer | akademik | kampus | ranking | araştırma | faq]
- source: Kaynak URL veya doküman adı
- verified: true/false — çift kontrol yapıldı mı?
- date: Verinin güncellendiği tarih
- priority: [high | medium | low] — retrieval önceliği

- audience_type: [kariyer_odakli | akademik | sosyal | genel]

Adım 4 — Kalite Testi

Knowledge base tamamlandıktan sonra yapılacak testler:

- 50 örnek soru ile retrieval doğruluğu testi (hedef: %85+ ilgili chunk dönsün)
- Hallucination testi: KB'de olmayan konular sorulduğunda AI 'bilmiyorum' desin
- Güncellik testi: Tüm istatistiklerin kaynağı 2024-2025 dönemine ait mi?
- Türkçe karakter ve encoding testi

3.3 Dosya Yapısı

Knowledge base dizin yapısı:

```
knowledge_base/ ├── raw_data/           ← Ham toplanan veriler |   ├── rankings/
|   ├── career/ |   ├── campus/ |   ├── faq/ |   ├── processed/
|   └── Temizlenmiş Markdown |   └── vectors/           ← ChromaDB / FAISS dosyaları |
metadata.json           ← Tüm chunk metadata'sı |   └── test_queries.json ← Test
soruları ve beklenen cevaplar
```

4. Etik Çerçeve & İçerik Kuralları

Bu bölüm, knowledge base'e eklenen içeriğin uyması gereken etik kuralları tanımlar. Her veri noktası bu kurallara göre filtrelenmelidir.

4.1 Zorunlu Kurallar

Kural	Açıklama	Kontrol Eden
✓Kaynaklı veri	Her istatistiğin kaynağı belgelenmiş olmalı	Data Ekibi
✓Güncel veri	İstatistikler en az 2023 sonrasına ait olmalı	Data Ekibi
✓Yalnızca İTÜ	Başka üniversite karşılaştırması olmamalı	Hoca Onayı
✓Kurumsal dil	Resmî, nötr, profesyonel dil kullanılmalı	İçerik Ekibi
✗Dini/siyasi içerik	Hiçbir dini veya siyasi referans olmamalı	Tüm Ekip
✗Sosyal/kişisel içerik	Kampüs sosyal hayatı abartılmamalı	Tüm Ekip
✗Rakip kötüleme	Diğer üniversiteler hiçbir şekilde kötülenmemeli	Tüm Ekip

4.2 İçerik Onay Süreci

- Tüm toplanan veri önce Data Ekibi tarafından işlenir
- Hassas içerikler (sıralama iddiaları, maaş rakamları) ekstra kaynakla doğrulanır
- Final KB, ekip lideri ve hoca tarafından onaylanır
- Onay verilmeden AI sistemine yüklenmez

5. Görev & Zaman Çizelgesi

Görev	Sorumlu	Başlangıç	Bitiş	Durum
B1.1 — QS/THE sıralama verisi topla	Kişi 1	Gün 1	Gün 2	☐ Bekliyor
B1.2 — YÖK Atlas mezun verisi	Kişi 1	Gün 2	Gün 3	☐ Bekliyor
B1.3 — İTÜ bölüm sayfası scrape	Kişi 2	Gün 1	Gün 3	☐ Bekliyor
B2.1 — LinkedIn mezun analizi	Kişi 2	Gün 2	Gün 5	☐ Bekliyor
B2.2 — Başarılı mezun profilleri	Kişi 1-2	Gün 3	Gün 5	☐ Bekliyor
B3.1 — FAQ bankası hazırla	Kişi 3	Gün 2	Gün 4	☐ Bekliyor
B4.1 — Ham veriyi Markdown'a çevir	Kişi 3	Gün 4	Gün 5	☐ Bekliyor
B4.2 — Chunking & embedding	Kişi 2	Gün 5	Gün 6	☐ Bekliyor
B4.3 — ChromaDB'ye yükle	Kişi 2	Gün 6	Gün 6	☐ Bekliyor
B4.4 — Retrieval kalite testi	Tüm Ekip	Gün 7	Gün 7	☐ Bekliyor
B4.5 — Hoca onayı	Ekip Lideri	Gün 8	Gün 8	☐ Bekliyor

5.1 Kritik Bağımlılıklar

- AI Motoru (C1) başlamadan önce en az %60 KB hazır olmalı → Gün 5
- Full KB test edilmiş ve onaylanmış olmalı → Gün 8
- Etkinlik öncesi son güncelleme yapılabilir → Gün 14

6. Teslim Kriterleri6. Teslim Kriterleri

Bu iş paketi aşağıdaki kriterler sağlandığında tamamlanmış sayılır:

Kriter	Ölçüm	Hedef
Veri kapsamı	Doldurulmuş veri kategorisi sayısı	Tüm kategoriler $\geq$ %80
Kaynak doğruluğu	Kaynaksız chunk sayısı	Sıfır kaynaksız chunk
Retrieval doğruluğu	Test sorularında ilgili chunk %'si	$\geq$ %85
Güncellik	2023 öncesi tarihli istatistik sayısı	Sıfır eskimiş veri
Etik uygunluk	Yasaklı içerik tespiti	Sıfır ihlal
Toplam chunk sayısı	Yüklenen chunk adedi	En az 200 chunk